

Derin Öğrenme Algoritma Türleri

Derin Öğrenme Algoritma Türleri

- **Evrişimli Sinir Ağları (Convolutional Neural Networks - CNN)**
- **Uzun Kısa Süreli Bellek Ağları (Long Short Term Memory Networks - LSTM)**
- **Tekrarlayan Sinir Ağları (Recurrent Neural Networks - RNN)**
- **Üretken Çekişmeli Ağlar (Generative Adversarial Networks - GAN)**
- **Radyal Temel Fonksiyon Ağları (Radial Basis Function Networks - RBFN)**
- **Çok Katmanlı Algılayıcılar (Multilayer Perceptrons - MLP)**
- **Kendi Kendini Düzenleyen Haritalar (Self Organizing Maps - SOM)**
- **Derin İnanç Ağları (Deep Belief Networks - DBN)**
- **Kısıtlı Boltzmann Makinaları (Restricted Boltzmann Machines - RBM)**
- **Otomatik Kodlayıcılar**

Derin Öğrenme Algoritma Türleri

Evrişimli Sinir Ağları (Convolutional Neural Network- CNN)

Görüntü işleme, sınıflandırma ve segmantasyon özellikleriyle öne çıkan (Diaz ve ark., 2021) CNN, başarılı uygulamaları sayesinde derin öğrenme çalışmalarında çok tercih edilen popüler ve güçlü modellerdendir. Derin öğrenmede sınıflandırma işlemleri, ön işlem yapılmaksızın CNN modeli ile diğer makine öğrenmesi tekniklerine kıyasla daha hızlı ve doğru bir şekilde yapılabilmektedir (Adem, 2018; Adem ve Közkurt, 2019). CNN bir girdinin görüntüsünü alabilen, görüntüdeki çeşitli özelliklere önem (weight ve bias) atayan ve görüntülerin birbirlerinden ayırt edilebilmesine imkân sağlayan ve aynı zamanda görüntülerin birbirleriyle olan ilişkilerini ortaya çıkarabilen ve bilgisayarlı görü işlevlerinde uzmanlaşmış derin öğrenme algoritmasıdır (Couliably ve ark., 2022).

Yapay Sinir Ağları (ANN)

- İnsan beynindeki nöron yapısından esinlenmiştir.
- Girdi verilerini öğrenerek tahmin yapar.
- Özellikle:
 - Sınıflandırma
 - Tahmin
 - Görüntü işleme
 - Ses tanımaalanlarında kullanılır.

Temel Problem

Klasik tam bağlı ağlar (Fully Connected Networks):

- Görüntülerde çok fazla parametre üretir.
- Hesaplama maliyeti yüksektir.
- Uzamsal bilgiyi koruyamaz.

Çözüm: CNN

CNN'ler görüntülerin:

- Kenar,
- Doku,
- Şekil,
- Nesne

özelliklerini otomatik öğrenebilir.

CNN Nedir?

Convolutional Neural Network (CNN)

CNN:

Özellikle görüntü verileri için geliştirilmiş derin öğrenme mimarisidir.

Görsel özellikleri otomatik çıkarır.

İnsan müdahalesi olmadan özellik öğrenebilir.

Kullanım Alanları

Yüz tanıma

Nesne tespiti

Otonom araçlar

Tıbbi görüntü analizi

Güvenlik sistemleri

El yazısı tanıma

Avantajları


Daha az parametre

Daha yüksek doğruluk

Uzamsal özellik koruma

Otomatik özellik çıkarımı

Giriş verisi olarak bir önceki katmanın çıktı verisi kullanılan derin öğrenmede; verilerin birden fazla özellik katmanlarının ve temsilinin öğrenilmesine dayanan bir yapı ile üst düzey özelliklerden alt düzey özellikler oluşturularak hiyerarşik bir temsil öğrenimi ortaya çıkmaktadır (Bengio ve ark., 2013). Şekilde derin öğrenme yapay sinir ağının genel yapısı gösterilmektedir.



Şekil. Derin öğrenme yapay sinir ağı (Çarkacı, 2018).

CNN Mimarisinin Genel Yapısı

CNN Katmanları

Bir CNN genellikle şu katmanlardan oluşur:

Girdi Katmanı (Input Layer)

Evrişim Katmanı (Convolution Layer)

Aktivasyon Fonksiyonu (ReLU)

Havuzlama Katmanı (Pooling Layer)

Tam Bağlı Katman (Fully Connected Layer)

Çıkış Katmanı

Veri Akışı

Görüntü → Özellik Çıkarma → Boyut Azaltma → Sınıflandırma

Convolution (Evrişim) İşlemi

Evrişim İşlemi

Evrişim:

Görüntü üzerinde küçük filtrelerin gezdirilmesi işlemidir.

Özellik çıkarımı yapılır.

Filtre (Kernel)

Örnek 3×3 filtre:

$$\begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix}$$

Bu filtre:

- Dikey kenarları tespit edebilir.

Mantık

Filtre görüntü üzerinde kaydırılır.

Her bölgede çarpma-toplama yapılır.

Yeni bir özellik haritası (feature map) oluşur.

Feature Map (Özellik Haritası) Özellik Haritası

Convolution sonucunda oluşan çıktıya: **Feature Map** denir.

Amaç

Görüntüdeki önemli özellikleri vurgulamak:

Kenarlar

Köşeler

Desenler

Dokular

Önemli Nokta

İlk katmanlar:

Basit özellikleri öğrenir.

Derin katmanlar:

Karmaşık nesneleri öğrenir.

Örnek:

İlk katman → kenar

Orta katman → göz

Derin katman → insan yüzü

Aktivasyon Fonksiyonu (ReLU)

ReLU Katmanı

Görevi

Negatif değerleri sıfırlar.
Doğrusal olmayan yapı kazandırır.
Eğitimi hızlandırır.

Avantajları

Hesaplama maliyeti düşüktür.
Vanishing Gradient problemini azaltır.
Modern CNN modellerinde yaygın kullanılır.

ReLU (Rectified Linear Unit)

Fonksiyon:

$$f(x) = \max(0, x)$$

Pooling Katmanı

Pooling (Havuzlama)

Pooling:

Özellik haritasının boyutunu küçültür. Hesaplama yükünü azaltır. Aşırı öğrenmeyi (overfitting) azaltabilir.

Türleri

1. Max Pooling

En büyük değeri seçer.

2. Average Pooling

Ortalama değeri alır.

Avantajları

Daha hızlı eğitim

Gürültü azaltma

Önemli özellikleri koruma

Fully Connected Layer

Tam Bağlı Katman

CNN'in son kısmıdır.

Görevi

Çıkarılan özellikleri: sınıflandırmak, karar vermek amacıyla kullanır.

Çalışma Mantığı

Tüm nöronlar birbirine bağlıdır.

Softmax aktivasyonu sık kullanılır.

Örnek:

Kedi , Köpek ,Araba İnsan gibi sınıflara ayırabilir.

CNN Eğitimi

CNN Nasıl Eğitilir?

Eğitim Süreci

Veri seti hazırlanır.

Görüntüler modele verilir.

Tahmin yapılır.

Hata hesaplanır.

Geri yayılım (Backpropagation)
uygulanır.

Ağırlıklar güncellenir.

Kullanılan Kavramlar

Loss Function

Gradient Descent

Epoch

Batch Size

Learning Rate

Avantajlar ve Dezavantajlar

CNN Avantajları

Yüksek görüntü başarıımı
Otomatik özellik çıkarımı
Büyük veriyle güçlü performans
Modern AI sistemlerinin temelidir

CNN Dezavantajları

Yüksek işlem gücü gerektirir
Büyük veri ihtiyacı olabilir
Eğitim süresi uzundur
Yorumlanabilirlik düşüktür

Popüler CNN Modelleri

LeNet

İlk başarılı CNN modellerinden biri

AlexNet

Derin öğrenme devrimini başlatmıştır

VGGNet

Derin ama düzenli yapı

ResNet

Çok derin ağlarda başarı sağlar

YOLO

Gerçek zamanlı nesne tespiti

.....

Kullanım Alanları

CNN Nereelerde Kullanılır?

Sağlık:

- MR analizi

- Kanser tespiti

Güvenlik:

- Yüz tanıma

- Kamera sistemleri

Otomotiv:

- Otonom sürüş

Endüstri:

- Hata tespiti

Tarım:

- Hastalık analizi

Derin Öğrenme Algoritma Türleri

Uzun Kısa Süreli Bellek Ağları (LSTM)

LSTM'ler, uzun sürede bağımlılıkları öğrenmek ve bunlara uyum sağlamak için programlanmış Tekrarlayan Sinir Ağları (RNN) olarak tanımlanmaktadır. Temel olarak geçmişteki bilgilerin mevcut bilgiyi açıklamasında ve gelecek bilginin tahmin edilmesinde etkili bir yöntemdir. Uzun ve kısa süreli depolama katmanının ana bileşeni, depolama bloğu verilen bir birimdir. Uzun ve kısa süreli bellek bloklarının giriş, çıkış ve unutma kapıları olmak üzere üç kapısı vardır. Bu kapılar hücrenin yazılmasını, okunmasını ve sıfırlanmasını gerçekleştirmektedir.

Forget Gate (Unutma Kapısı)

Görevi:

- Önceki bilgilerin hangisinin silineceğini belirlemek.

Matematiksel ifade:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

Açıklama

- Çıktı 0 ile 1 arasındadır.
- 0 → bilgiyi unut
- 1 → bilgiyi koru

Önemi

Gereksiz bilgilerin temizlenmesini sağlar.

Input Gate (Giriş Kapısı)

Görevi:

- Yeni bilgilerin hafızaya eklenmesini kontrol etmek.

Formül:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

Yeni aday bilgi:

$$\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$$

İşlev

Yeni öğrenilen bilgilerin ne kadarının saklanacağını belirler.

Hücre Durumu Güncellemesi

Yeni hücre durumu:

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Açıklama

- Eski bilgiler filtrelenir.
- Yeni bilgiler eklenir.
- Uzun süreli hafıza korunur.

Sonuç

LSTM:

- geçmiş bilgileri etkin şekilde taşıyabilir.

Output Gate (Çıkış Kapısı)

Görevi:

- Çıktıya hangi bilgilerin aktarılacağını belirlemek.

Formül:

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$

Gizli durum:

$$h_t = o_t * \tanh(C_t)$$

İşlev

Bir sonraki adıma aktarılacak bilgiyi belirler.

LSTM Nasıl Çalışır?

Adımlar

Giriş verisi alınır.

Forget Gate gereksiz bilgileri siler.

Input Gate yeni bilgileri ekler.

Cell State güncellenir.

Output Gate çıktı üretir.

Sonuç

Model:

geçmiş bilgileri unutmaz,

uzun bağımlılıkları öğrenebilir.

LSTM Kullanım Alanları

Doğal Dil İşleme (NLP)

Metin üretimi

Çeviri

Duygu analizi

Zaman Serileri

Hisse senedi tahmini

Hava durumu tahmini

Sensör verileri

Ses İşleme

Konuşma tanıma

Ses sentezi

Sağlık

Hasta verisi analizi

EKG sinyalleri

LSTM Avantajları

LSTM Avantajları

Uzun süreli bağımlılık öğrenebilir

Gradient Vanishing problemini azaltır

Sıralı verilerde yüksek başarı sağlar

NLP uygulamalarında çok etkilidir

Güçlü Olduğu Alanlar

Dil modelleri

Tahmin sistemleri

Zaman serileri

LSTM Dezavantajları

Eğitim süresi uzundur
Hesaplama maliyeti yüksektir
Çok fazla parametre içerir
Büyük veri ve güçlü donanım
gerektirebilir

Karşılaştırma

LSTM:

RNN'den daha güçlü,
ancak daha yavaştır.

Derin Öğrenme Algoritma Türleri

Tekrarlayan Sinir Ağları (RNN)

LSTM'lerden sağlanan girdinin RNN'lerin girdi olarak kullanılmasına izin veren bir döngü oluşturan bazı yönlendirilmiş bağlantılardan oluşmaktadır. Bu girdiler, derinlemesine gömülmekte ve LSTM'lerin ezberleme yeteneğini zorlamaktadır. Bu durum girdilerin dahili bellekte bir süre emilmesini sağlamaktadır. Bu nedenle RNN'ler, LSTM'ler tarafından korunan girdilere bağımlıdır ve LSTM'lerin senkronizasyon olgusu altında çalışmaktadır.

Derin Öğrenme Algoritma Türleri

RNN'ler çoğunlukla görüntüye altıyazı ekleme, zaman serisi analizi, el yazısı verileri tanıma ve verileri makinelere çevirmede kullanılmaktadır. RNN'ler, süre t olarak tanımlanmışsa çıkış beslemeleri $(t-1)$ sürede takip etmektedir. Ardından, t tarafından belirlenen çıkış, $t+1$ girişi beslemektedir. Benzer şekilde, bu işlemler herhangi bir uzunlukta oluşan tüm girdiler için tekrarlanmaktadır. Ayrıca, RNN'ler geçmiş bilgileri depolamakta ve model boyutu artırılmasına rağmen girdi boyutunda bir artış olmamaktadır.

Derin Öğrenme Algoritma Türleri

Üretken Çekişmeli Ağlar (GAN)

GAN'lar, eğitim verileriyle eşleşen yeni veri örnekleri oluşturmak için kullanılan derin öğrenme algoritmaları olarak tanımlanmaktadır. GAN genellikle yanlış veri üretmeyi öğrenen bir üretici ve bu yanlış veriden öğrenerek kendini uyarlayan bir ayırmacı olmak üzere iki bileşenden oluşmaktadır. GAN'lar, sahte verileri ve gerçek verileri üreterek ve anlayarak simülasyonda çalışmaktadır. Bu verileri anlamaya yönelik eğitim sırasında, üretici farklı türde sahte veriler üretmektedir. Burada ayırmacı hızla uyum sağlamayı ve buna yanlış veri olarak yanıt vermeyi öğrenmektedir.

Derin Öğrenme Algoritma Türleri

Radyal Temelli Fonksiyon Ağları (RBFN)

RBFN'ler, ileri beslemeli bir yaklaşımlı izleyen ve aktivasyon fonksiyonunda radyal temelli fonksiyonları kullanan sinir ağı türleridir. Genellikle zaman serisi tahmini, regresyon testi ve sınıflandırma için kullanılan girdi katmanı, gizli katman ve çıktı katmanı olmak üzere üç katmandan oluşmaktadır. RBFN'ler, eğitim veri setinde bulunan benzerlikleri ölçerek bu görevleri yerine getirmektedir. Genellikle, bu verileri girdi katmanına besleyen bir girdi vektörüne sahiptir. Böylece tanımlamayı doğrular ve önceki veri kümelerini karşılaştırarak sonuçları yayınlarlar.

Derin Öğrenme Algoritma Türleri

Girdi katmanında bu verilere duyarlı nöronlar bulunmakta ve katmandaki düğümler veri sınıfını sınıflandırmada etkilidir. Nöronlar, giriş katmanı ile yakın bütünleşme içinde çalışsalar da başlangıçta gizli katmanda bulunmaktadır. Gizli katman, çıkışın nöronun merkezine olan uzaklığıyla ters orantılı olan Gauss transfer fonksiyonlarını içermektedir. Çıkış katmanı, Gauss fonksiyonlarının nöronda parametre olarak iletildiği ve çıktının üretildiği radyal tabanlı verilerin doğrusal kombinasyonlarına sahiptir.

Derin Öğrenme Algoritma Türleri

Çok Katmanlı Algılayıcılar (MLP)

MLP'ler, derin öğrenme teknolojisinin temelidir. Çeşitli algılayıcı katmanlarına sahip ileri beslemeli sinir ağları sınıfına aittir. Bu algılayıcıların içinde çeşitli aktivasyon fonksiyonları vardır. MLP'ler ayrıca bağlantılı giriş ve çıkış katmanlarına sahiptir ve sayıları aynıdır. Ayrıca bu iki katmanın arasında gizli kalan bir katman vardır. MLP'ler çoğunlukla görüntü ve konuşma tanıma sistemleri veya diğer bazı çeviri yazılımı türlerini oluşturmak için kullanılır.

Derin Öğrenme Algoritma Türleri

MLP'lerin çalışması, girdi katmanındaki verileri besleyerek başlar. Katmanda bulunan nöronlar, bir yönde geçen bir bağlantı kurmak için bir grafik oluşturmaktadır. Bu girdi verilerinin ağırlığının gizli katman ile girdi katmanı arasında olduğu bulunmuştur. MLP'ler, hangi düğümlerin harekete geçmeye hazır olduğunu belirlemek için aktivasyon fonksiyonlarını kullanmaktadır. Bu aktivasyon fonksiyonları arasında tanh fonksiyonu, sigmoid ve ReLU'lar bulunmaktadır. MLP'ler, temel olarak, verilen veri setinden istenen çıktıyı elde etmek için katmanların ne tür bir korelasyona hizmet ettiğini anlamak için modelleri eğitmek için kullanılmaktadır.

Derin Öğrenme Algoritma Türleri

Kendi Kendini Düzenleyen Haritalar (SOM)

SOM'lar, yapay ve kendi kendini organize eden sinir ağları ile verilerin boyutlarını anlamak ve verileri görselleştirmek için tasarlanmıştır. Veriler genellikle yüksek boyutludur. SOM'lar, farklı düğümlerin ağırlıklarını başlatmakta ve ardından verilen eğitim verilerinden rastgele vektörler seçerek verilerin görselleştirilmesine yardımcı olmaktadır. Bağımlılıkların anlaşılabilmesi ve görelî ağırlıkları bulmak için her düğümü incelemektedir. Kazanan düğüme karar verilmekte ve buna En İyi Eşleşen Birim (BMU) denilmektedir. Daha sonra SOM'lar bu kazanan düğümleri keşfetmektedir. Düğüm BMU'ya ne kadar yakınsa, ağırlığı tanıma ve daha fazla aktivite gerçekleştirme şansı o kadar fazladır. Ayrıca, BMU'ya daha yakın hiçbir düğümün kaçırılmamasını sağlamak için birden fazla yineleme yapılmaktadır.

Derin Öğrenme Algoritma Türleri

Derin İnanç Ağları (DBN)

DBN'ler, tesadüfi etkenlere maruz değişkenlerin yanı sıra çeşitli gizli katmanlara sahip oldukları için üretken modeller olarak adlandırılmaktadır. Gizli değişken, ikili değerlere sahip olduğu için gizli birim olarak adlandırılmaktadır. DBN'ler ayrıca Boltzmann Makineleri olarak da bilinmektedir. Bunun nedeni önceki ve ardışık katmanlarla iletişim kurmak için birbirinin üzerine istiflenmesidir. DBN'ler, aşağıdan yukarıya geçiş yaklaşımını izleyen her katmandaki gizli değerde bulunan değerlerden öğrenmektedir. DBN'ler, hareketli nesneleri yakalamanın yanı sıra video ve görüntü tanıma gibi uygulamalarda kullanılmaktadır.

Derin Öğrenme Algoritma Türleri

Kısıtlanmış Boltzmann Makineleri (RBM'ler)

RBM'ler verilen girdi setindeki olasılık dağılımından öğrenen tesadüfi değişken sinir ağlarına benzemektedir. Bu algoritma esas olarak boyut küçültme, regresyon ve sınıflandırma, konu modelleme alanında kullanılmakta ve DBN'lerin yapı taşları olarak kabul edilmektedir. RBM'ler, görünür katman ve gizli katman olmak üzere iki katmandan oluşmaktadır. Bu katmanların her ikisi de gizli birimler aracılığıyla bağlanmaktadır. RBM'lerin işleyişi, girdilerin kabul edilmesi ve bunların sayılara çevrilmesiyle gerçekleştirilmektedir. RBM'ler, her girdinin ağırlığını hesaba katmaktadır. Bu girdi ağırlıkları yeniden yapılandırılmış girdilere dönüştürülmektedir. Daha sonra, bu çevrilmiş girdilerin her ikisi de bireysel ağırlıklarla birlikte birleştirilmektedir. Bu girdiler son olarak aktivasyonun gerçekleştirildiği görünür katmana itilmekte ve kolayca yeniden yapılandırılabilen çıktılar üretilmektedir.

Derin Öğrenme Algoritma Türleri

Otomatik Kodlayıcılar

Otomatik kodlayıcılar, girişlerin ve çıkışların genellikle aynı olduğu verileri kopyalayan yüksek düzeyde eğitilmiş özel bir sinir ağı türüdür. Kodlayıcı, kod ve kod çözücü olmak üzere üç bileşenden oluşmaktadır. Denetimsiz öğrenme ile ilgili sorunları çözmek için tasarlanmıştır. Otomatik kodlayıcılar görüntüyü veya girişi kodlayarak boyutunu küçültmektedir. Kod çözücü görüntü düzgün görünmüyorsa, açıklama için sinir ağına iletmektedir. Ardından netleştirilmiş görüntü, yeniden yapılandırılmış görüntü olarak adlandırılarak yeni veri oluşturulmaktadır. Kodlayıcıdaki verinin girdi boyutu ile kod çözücü sonucundan oluşan yeni verinin nöron sayısı (boyutu) aynı olmaktadır.